

Dominando Google AI Studio: Ingeniería de Prompts Experta para el Desarrollo de Aplicaciones de IA y Despliegue en Vercel

Introducción: Su Camino hacia la Experiencia en AI Studio

La evolución de la inteligencia artificial ha transformado radicalmente el desarrollo de software, y plataformas como Google AI Studio se han posicionado como herramientas fundamentales en este nuevo paradigma. Google AI Studio es un entorno rápido y gratuito que permite a desarrolladores y usuarios ocasionales experimentar con los modelos Gemini más recientes de Google DeepMind. Ofrece acceso a potentes modelos de lenguaje grande (LLM), capacidades de generación de imágenes, ejecución de tareas complejas mediante razonamiento y una comprensión multimodal fluida de texto, código, imágenes, audio y video.¹ Su generosa capa gratuita y sus planes flexibles de pago por uso reducen significativamente la barrera de entrada al desarrollo de IA.¹

Google AI Studio es un punto de partida excelente y un laboratorio para ideas de IA. Sin embargo, para llevar una aplicación de IA desde la fase de prototipo a un entorno de producción escalable, se requiere una comprensión más profunda de la transición y adaptación del código para plataformas de alojamiento externas. Esto implica reconocer que, si bien AI Studio es ideal para la ideación y la experimentación rápida, una aplicación lista para el despliegue a menudo necesita un entorno más robusto para su operación continua.

En este contexto, la ingeniería de prompts avanzada se vuelve crucial para construir aplicaciones de IA robustas. Esta disciplina, que consiste en el arte y la ciencia de elaborar entradas efectivas para obtener respuestas precisas y de alta calidad de los modelos de IA, es indispensable para las aplicaciones de IA de nivel profesional.³ Las instrucciones genéricas son insuficientes; se requieren instrucciones "mega detalladas y profesionales" para garantizar resultados consistentes y fiables. La ingeniería de prompts puede ofrecer mejoras significativas en el rendimiento de

manera mucho más rápida y rentable que el ajuste fino de modelos, requiriendo datos mínimos y permitiendo una iteración ágil.⁶ Esto posiciona la ingeniería de prompts no solo como una habilidad especializada, sino como una metodología de desarrollo fundamental para adaptar y controlar rápidamente los LLM, lo que es esencial para la agilidad y eficiencia en el desarrollo de productos de IA.

Para el despliegue de aplicaciones impulsadas por AI Studio, Vercel emerge como una elección estratégica. Vercel se presenta como la "Nube de IA", proporcionando herramientas para desarrolladores e infraestructura en la nube para construir, escalar y asegurar experiencias web, incluidas las aplicaciones de IA.⁷ Facilita despliegues fluidos conectados a Git, reversiones instantáneas y distribución global, simplificando el ciclo de vida del despliegue.⁷ Además, el Vercel AI SDK estandariza la integración de modelos de IA de varios proveedores, incluido Google Gemini, lo que permite a los desarrolladores centrarse en la lógica de la aplicación en lugar de los detalles técnicos específicos del proveedor.⁸ La sinergia entre AI Studio para la ideación y Vercel para la realización es clara: AI Studio permite la experimentación, mientras que Vercel proporciona el entorno necesario para transformar un prototipo en una aplicación web escalable y de grado de producción.

Google AI Studio: El Patio de Juegos del Desarrollador

Google AI Studio es un entorno diseñado para la prototipación rápida y la experimentación con inteligencia artificial. Ofrece acceso directo a los potentes modelos Gemini de Google, como Gemini 2.5 Pro y 2.5 Flash, que se distinguen por sus amplias ventanas de contexto de 2 millones de tokens, capacidades de almacenamiento en caché de contexto y funciones de búsqueda con conexión a tierra para una comprensión más profunda y respuestas más precisas.¹

La interfaz de usuario de AI Studio es intuitiva y cuenta con elementos clave que facilitan la interacción. Los usuarios pueden iniciar nuevas conversaciones, acceder a un historial de chat para retomar conversaciones previas, y explorar una galería de prompts para inspirarse en las capacidades de los modelos Gemini.² Una característica vital es la selección de modelos, que permite elegir entre quince modelos únicos de Gemini según el caso de uso, desde la generación de imágenes hasta el resumen de videos largos.² Además, AI Studio incorpora funciones innovadoras como la transmisión en tiempo real, que permite compartir la cámara y el

escritorio con Gemini para obtener asistencia visual, y cargas multimodales, que facilitan la conexión directa con Google Drive o la carga de imágenes, videos y otros archivos.² El centro de la interacción es la ventana de chat, similar a otros chatbots, donde se producen las conversaciones con Gemini, y un contador de tokens preciso ayuda a los desarrolladores a gestionar el tamaño de la ventana de contexto.²

Las aplicaciones prácticas de Google AI Studio son diversas y abarcan desde el apoyo educativo hasta la asistencia creativa. Puede funcionar como un tutor personal, explicando contenido complejo o creando planes de estudio a partir de materiales cargados.² También es una herramienta valiosa para la escritura, ayudando en las fases de lluvia de ideas y edición, especialmente útil para la creación de esquemas.² Los modelos Gemini más recientes son eficaces para la generación de imágenes, permitiendo mejoras iterativas.² Además, puede asistir en la redacción de correos electrónicos y publicaciones en redes sociales, adaptándose a preferencias de estilo y tono.²

Comprender la Sección "Build": Del Concepto a la Funcionalidad Inicial de IA

La pregunta del usuario hace referencia a una sección "build" donde "Google Studio se encarga de todo". Si bien las descripciones explícitas de una sección de "construcción" que genere una base de código de aplicación completamente desplegable son limitadas en los materiales de investigación, la funcionalidad descrita en AI Studio implica un entorno donde los prompts impulsan la creación de características impulsadas por IA.¹ La experiencia de un usuario que intentó construir una aplicación de tarjetas de felicitación animadas con AI Studio ilustra este punto. El usuario utilizó un prompt específico como "Por favor, crea una aplicación que genere tarjetas de felicitación lindas y únicas, usando Imagen para visuales inspirados en anime, y Gemini para mensajes conmovedores" directamente dentro de AI Studio.¹⁰ Esto sugiere que la sección "build" probablemente implica una prototipación conversacional de aplicaciones a través de prompts detallados.

Es importante destacar que, aunque AI Studio puede ayudar a generar ideas y prototipos de aplicaciones, la experiencia de usuario mencionada revela que la transición a un entorno de despliegue externo como Vercel no es trivial. El código generado por AI Studio a menudo requiere "ajustes finos" y asistencia externa para funcionar correctamente en entornos locales o de Vercel, especialmente en lo que respecta a los scripts importmap.¹⁰ Esto indica que la función de "construcción" de AI

Studio se asemeja más a la generación de fragmentos de código o marcos conceptuales que a un paquete de aplicación listo para producción y exportable. La interacción con un "agente de IA" dentro de AI Studio para generar la aplicación puede ser "obstinada" o poco útil con ajustes específicos para el despliegue externo.¹⁰ Esto sugiere que la sección "build" es menos un entorno de desarrollo integrado (IDE) tradicional y más una experiencia de desarrollo conversacional impulsada por un agente. Un ingeniero de prompts experto debe comprender no solo cómo interactuar con el modelo, sino también cómo interactuar con el agente de IA que genera la aplicación, y anticipar sus limitaciones al pasar a entornos externos como Vercel.

Distinguir Google AI Studio de Otras Plataformas de IA de Google Cloud

Comprender las diferencias entre Google AI Studio y otras plataformas de IA de Google Cloud es fundamental para seleccionar la herramienta adecuada en cada etapa del ciclo de vida del desarrollo de aplicaciones de IA.

- **Google AI Studio:** Como se mencionó, es un entorno gratuito e intuitivo diseñado para la prototipación rápida y la experimentación con modelos Gemini. Es ideal para explorar las capacidades de la IA e iterar rápidamente sobre ideas de prompts.¹ Se considera un punto de partida para desarrolladores y usuarios casuales.
- **Vertex AI:** Esta es una plataforma de desarrollo de IA unificada, totalmente gestionada y lista para empresas, destinada a la construcción y uso de IA generativa.¹¹ Ofrece herramientas para entrenar, probar y ajustar modelos de aprendizaje automático, desplegar modelos en producción y construir rápidamente aplicaciones de IA generativa con Gemini.¹¹ Incluye Vertex AI Studio para la prototipación, Agent Builder y más de 200 modelos fundacionales.¹¹ Está orientada a científicos de datos e ingenieros de ML para la gestión del ciclo de vida completo del modelo y soluciones de IA a escala empresarial. Vertex AI también aprovecha los modelos Gemini para la generación de código.¹²
- **Firestore Studio:** Se describe como un entorno de desarrollo basado en la nube para construir y entregar aplicaciones de IA de pila completa de calidad de producción (APIs, backends, frontends, móvil).¹³ Unifica Project IDX con agentes de IA especializados y asistencia de Gemini en Firestore. Permite importar proyectos existentes, prototipado rápido en lenguaje natural (generando aplicaciones completas con prompts multimodales) y proporciona asistencia de

codificación de IA.¹¹ Está diseñado para desarrolladores full-stack que buscan un entorno de desarrollo y despliegue integrado.

La existencia de Vertex AI y Firebase Studio junto con AI Studio indica una progresión clara o diferentes casos de uso. AI Studio es para la ideación y pruebas rápidas. Vertex AI es para la gestión del ciclo de vida de ML de grado empresarial y el entrenamiento/despliegue de modelos personalizados. Firebase Studio es para el desarrollo de aplicaciones de pila completa con asistencia de IA integrada y alojamiento. Para un experto, comprender estas distinciones es crucial para elegir la herramienta adecuada para la etapa correcta del proyecto, especialmente al pasar del prototipo a la producción. Esto significa que el informe debe guiar al usuario sobre cuándo es apropiado hacer la transición de AI Studio a una plataforma más robusta o cómo integrar la salida de AI Studio en un flujo de trabajo de desarrollo más amplio.

El Arte y la Ciencia de la Ingeniería de Prompts Profesional

La ingeniería de prompts es una disciplina fundamental para interactuar eficazmente con los modelos de IA, especialmente los modelos de lenguaje grande (LLM). Para convertirse en un verdadero experto, es necesario ir más allá de las instrucciones básicas y adoptar principios y estrategias avanzadas que garanticen respuestas precisas, consistentes y de alta calidad.

Principios Fundamentales para Prompts Precisos

La base de una ingeniería de prompts eficaz reside en la claridad y la especificidad de las instrucciones proporcionadas al modelo.

- **Establecer metas, objetivos y acciones deseados claros:** Es fundamental utilizar verbos de acción para especificar exactamente lo que el modelo debe hacer. Por ejemplo, en lugar de una instrucción vaga como "Háblame sobre el cambio climático", una instrucción profesional sería "Redacta un ensayo de 500 palabras que discuta el impacto del cambio climático en las comunidades costeras, dirigido a jóvenes preocupados por la sostenibilidad".³ Además, se debe definir la longitud y el formato deseados de la salida, y especificar la audiencia

objetivo para guiar la respuesta del modelo.³

- **Proporcionar contexto e información de fondo completa:** Incluir hechos y datos relevantes es esencial. Por ejemplo, "Dado que las temperaturas globales han aumentado 1 grado Celsius desde la era preindustrial, discute las posibles consecuencias para el aumento del nivel del mar".³ También es importante definir términos y conceptos clave, y hacer referencia a fuentes o documentos específicos si el modelo debe basar su respuesta en ellos.³
- **Definir restricciones explícitas y formatos de respuesta deseados:** Se debe especificar claramente qué debe hacer el modelo y qué debe evitar. Esto incluye dictar el formato de salida, como una tabla, una lista con viñetas, un objeto JSON o una sola oración.³ Por ejemplo, "Resume este texto en una frase" ⁵ o "Aclara el formato. Especifica la estructura o presentación deseada de las respuestas".⁴

La repetición en múltiples fuentes sobre la necesidad de especificidad, claridad, contexto y formato subraya que la creación de prompts no es solo una conversación, sino el establecimiento de un "contrato" con el modelo. Cuanto más preciso sea el prompt, más predecible y controlable será la salida, lo cual es de suma importancia para construir aplicaciones fiables. Esto eleva la ingeniería de prompts de un arte conversacional a una disciplina estructurada y casi programática.

Estrategias Avanzadas de Prompts para Aplicaciones de IA Complejas

Para desarrollar aplicaciones de IA sofisticadas, las estrategias de prompts deben ir más allá de los principios fundamentales.

- **Aprovechar ejemplos de pocas tomas (few-shot) para el reconocimiento de patrones y la consistencia:** Proporcionar ejemplos de pares de entrada-salida deseados es una técnica poderosa. Esto ayuda al modelo a identificar patrones para el formato, la fraseología y el alcance, lo que lleva a resultados más precisos. Se recomienda encarecidamente incluir siempre ejemplos de pocas tomas, ya que los prompts sin ellos son menos efectivos.⁵ Por ejemplo, para asegurar respuestas concisas, se pueden proporcionar ejemplos de respuestas cortas y directas.⁵
- **Desglosar y encadenar prompts para tareas de múltiples pasos:** Para tareas complejas, la descomposición en componentes más simples es clave. Esto puede implicar crear un prompt por instrucción o encadenar prompts donde la salida de uno se convierte en la entrada del siguiente.⁵ Un ejemplo claro es: "Encadenar

prompts: Para tareas complejas que implican múltiples pasos secuenciales, haga de cada paso un prompt y encadene los prompts en una secuencia".⁵

- **Implementar la llamada a herramientas y la ejecución de funciones dentro de los prompts:** Los modelos Gemini y el Vercel AI SDK admiten la llamada a funciones, lo que permite que el modelo utilice herramientas externas (por ejemplo, APIs de clima, conexión a tierra de búsqueda) para completar tareas.¹ Esto permite la creación de "agentes" que pueden interactuar con el mundo real. Por ejemplo, se puede definir una herramienta `getWeather` con parámetros y una función `execute`, y luego pedir al modelo que la utilice para obtener información meteorológica.⁹ La capacidad de llamar a herramientas y funciones va más allá de la simple generación de texto. Introduce el concepto de agentes de IA que pueden "conectarse a tierra en el mundo real" haciendo preguntas y recibiendo respuestas de los resultados de las herramientas.¹⁵ Esto implica que la ingeniería de prompts avanzada no se trata solo de generar texto, sino de orquestar flujos de trabajo complejos donde el LLM actúa como un motor de razonamiento que interactúa con sistemas externos. Este es un salto significativo desde el prompting básico y es directamente relevante para la construcción de aplicaciones de IA sofisticadas.

La siguiente tabla resume algunas de las técnicas de ingeniería de prompts avanzadas y su aplicación:

| Técnica de Ingeniería de Prompts Avanzada | Descripción | Beneficio Clave para el Desarrollo de Aplicaciones | Ejemplo de Prompt | Fuentes Relevantes |
|-----------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------|
| Few-shot Prompting (Ejemplos de Pocas Tomas) | Proporcionar al modelo un pequeño número de ejemplos de entrada-salida deseados para que aprenda el patrón, el formato o el estilo. | Mejora la consistencia y precisión de las respuestas, reduce las "alucinaciones" y guía el modelo hacia el formato deseado. | "Traduce las siguientes oraciones al español, manteniendo el tono formal: Inglés: 'Please provide a summary.' Español: 'Por favor, proporcione un resumen.' Inglés: 'Could you | 5 |

| | | | | |
|----------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| | | | <p>elaborate on this point?' Español: '¿Podría elaborar sobre este punto?' Inglés: 'What are the key findings?' Español: '¿Cuáles son los hallazgos clave?'"</p> | |
| Chained Prompts (Prompts Encadenados) | <p>Descomponer una tarea compleja en una serie de pasos secuenciales, donde la salida de un prompt se convierte en la entrada del siguiente.</p> | <p>Permite abordar tareas complejas que requieren múltiples etapas de procesamiento o razonamiento, mejorando la coherencia y la calidad del resultado final.</p> | <p>"Paso 1: Extrae todos los nombres de empresas del siguiente texto. Paso 2: Para cada empresa identificada en el Paso 1, busca su sector industrial. Paso 3: Genera un informe en formato JSON que liste cada empresa y su sector."</p> | 5 |
| Tool Calling (Llamada a Herramientas) | <p>Instruir al modelo para que utilice funciones o herramientas externas predefinidas para obtener información o realizar acciones que no puede hacer por sí mismo.</p> | <p>Extiende las capacidades del modelo más allá de su conocimiento intrínseco, permitiéndole interactuar con datos en tiempo real, bases de datos o servicios externos.</p> | <p>"Eres un asistente meteorológico. Utiliza la herramienta <code>getWeather(location: string)</code> para obtener la temperatura actual en una ciudad específica. Si el usuario pregunta por el</p> | 1 |

| | | | | |
|------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| | | | clima en 'Londres', llama a la herramienta con getWeather('Londres')." | |
| Contextual Grounding (Conexión a Tierra Contextual) | Proporcionar al modelo documentos, datos o información específica para que base sus respuestas, en lugar de depender únicamente de su conocimiento pre-entrenado. | Reduce las "alucinaciones" y garantiza que las respuestas sean precisas y relevantes para la información proporcionada, crucial para aplicaciones basadas en datos específicos. | "Basado en el informe financiero adjunto, analiza la rentabilidad de la empresa durante los últimos cinco años. Enfócate solo en los datos presentados en el informe." | 3 |
| Structured Output (Salida Estructurada) | Especificar el formato exacto en el que el modelo debe generar su respuesta (ej., JSON, XML, lista con viñetas, tabla), a menudo utilizando esquemas. | Facilita el procesamiento programático de las respuestas del modelo, esencial para integrar la IA en flujos de trabajo de software y bases de datos. | "Genera un objeto JSON con los siguientes campos: 'nombre', 'edad', 'ciudad'. Ejemplo: {'nombre': 'Juan', 'edad': 30, 'ciudad': 'Madrid'}." | 5 |

Optimización del Comportamiento del Modelo con Parámetros

Más allá de la formulación del prompt en sí, los parámetros del modelo ofrecen un control granular sobre cómo se generan las respuestas.

- **Controlar la creatividad y el determinismo:**
 - **Temperatura:** Este parámetro controla el grado de aleatoriedad en la selección de tokens. Una temperatura de 0 produce una respuesta

determinista (la opción de mayor probabilidad siempre se selecciona), mientras que valores más altos conducen a resultados más diversos y creativos.⁵ Para aplicaciones de producción, la predictibilidad es primordial, por lo que ajustar la temperatura ayuda a asegurar que las respuestas no se desvíen inesperadamente.

- **topK:** Determina cómo el modelo selecciona los tokens para la salida. Un topK de 1 significa que se selecciona el token más probable (decodificación codiciosa), mientras que un topK de 3 significa que el siguiente token se selecciona entre los 3 más probables utilizando la temperatura.⁵
- **topP:** Modifica cómo el modelo selecciona los tokens para la salida. Los tokens se seleccionan de los más a los menos probables hasta que la suma de sus probabilidades sea igual al valor de topP.⁵
- **Gestionar la longitud de la salida y las condiciones de detención:**
 - **Max output tokens (Máximo de tokens de salida):** Especifica el número máximo de tokens que se pueden generar en la respuesta. Un token equivale aproximadamente a cuatro caracteres, y 100 tokens corresponden a unas 60-80 palabras.⁵ Este parámetro es crucial para controlar los costos y el diseño de la interfaz de usuario, evitando generaciones excesivamente largas.
 - **Stop sequences (Secuencias de detención):** Permiten definir una secuencia de caracteres que indica al modelo que debe dejar de generar contenido. Es importante evitar secuencias que puedan aparecer naturalmente en el contenido generado.⁵ Son esenciales para salidas estructuradas donde se requiere un final específico.

Este nivel de control sobre los parámetros del modelo es lo que distingue a un ingeniero de prompts experto de un usuario casual. Permite una fiabilidad y consistencia que son vitales para las aplicaciones en producción.

Refinamiento y Depuración Iterativa de Prompts

La ingeniería de prompts es un proceso inherentemente iterativo. Las estrategias de diseño de prompts a menudo requieren múltiples ciclos de prueba y ajuste.

- **Estrategias de iteración:** Si los resultados no son los esperados, se pueden probar diferentes frases o palabras, cambiar a una tarea análoga que logre el mismo resultado, o alterar el orden del contenido del prompt (ej., [ejemplos][contexto][entrada]).⁵

- **Evaluación:** Es fundamental definir criterios de éxito claros y desarrollar casos de prueba empíricos para evaluar el rendimiento del prompt.⁶ Esto se alinea directamente con las prácticas de desarrollo de software para pruebas y aseguramiento de la calidad.
- **Respuestas de reserva (fallback):** Comprender las respuestas de reserva, como las que se activan cuando un prompt o una respuesta desencadenan un filtro de seguridad (ej., "No puedo ayudarte con eso, ya que solo soy un modelo de lenguaje"), es importante. En tales casos, una posible solución es aumentar la temperatura del modelo.⁵

La insistencia en las "estrategias de iteración", la "definición de criterios de éxito" y el "desarrollo de casos de prueba" ⁵ refleja directamente las prácticas de prueba y control de calidad del desarrollo de software. Esto implica que la ingeniería de prompts no es una tarea única, sino un ciclo continuo de diseño, prueba y refinamiento, muy parecido al desarrollo de código tradicional. Un ingeniero de prompts experto aplica metodologías sistemáticas de depuración y evaluación a sus prompts.

Conectando Google AI Studio y Vercel: Despliegue Fluido de Aplicaciones de IA

La transición de un prototipo de IA creado en Google AI Studio a una aplicación de producción desplegada en Vercel requiere una comprensión clara de las capacidades de ambas plataformas y cómo se complementan.

Vercel como la Nube de IA: Capacidades para Aplicaciones de IA Modernas

Vercel se ha posicionado como una plataforma líder para construir, escalar y asegurar aplicaciones web, y ha extendido sus capacidades específicamente para las aplicaciones de IA. Ofrece despliegue global, reversiones instantáneas y características de seguridad robustas como protección DDoS y Web Application Firewall (WAF).⁷ La plataforma se integra con frameworks populares como Next.js, React, Vue, Svelte y Node.js, y proporciona una interfaz unificada para los principales

modelos de IA a través de su AI SDK.⁷

Vercel está optimizado para cargas de trabajo de IA, lo que se manifiesta en su soporte para respuestas de streaming y opciones de almacenamiento en caché como Incremental Static Regeneration (ISR) y Vercel KV (una base de datos Redis gestionada) para mejorar el rendimiento.¹⁶ Vercel no es solo una plataforma de alojamiento genérica; se comercializa explícitamente como la "Nube de IA"⁷ y ofrece características específicas como el AI SDK⁸ y estrategias de almacenamiento en caché¹⁶ adaptadas a las aplicaciones de IA. Esto demuestra una comprensión profunda de los requisitos únicos de las aplicaciones de IA, como la transmisión en tiempo real, el contenido dinámico y el potencial de un alto número de llamadas a la API. Para un experto, esto significa que Vercel no es solo un objetivo de despliegue, sino una plataforma asociada que apoya y optimiza activamente la integración de la IA.

Integración de Google Gemini con Vercel AI SDK

El Vercel AI SDK es un kit de herramientas TypeScript diseñado para estandarizar la integración de modelos de lenguaje grande (LLM) de varios proveedores, incluido Google Gemini, en aplicaciones web.⁸

Configuración: Para comenzar, se deben instalar los paquetes `ai` y `@ai-sdk/google` utilizando un gestor de paquetes como npm, yarn o pnpm. Es crucial configurar la clave API de Google Gemini como una variable de entorno (por ejemplo, `GOOGLE_GENERATIVE_AI_API_KEY`) en el entorno de Vercel para asegurar el acceso al modelo.¹

Ejemplos de código prácticos: El AI SDK simplifica la interacción con los modelos Gemini para diversas funcionalidades:

- **Generación de texto:** Un ejemplo básico implica el uso de `generateText` con un modelo Gemini, como `google('gemini-2.0-flash')` para obtener una respuesta de texto simple.⁹
- **Streaming:** Para aplicaciones de chat o interacciones en tiempo real, se utiliza `streamText` para obtener respuestas generadas en tiempo real, lo que mejora la experiencia del usuario.⁹
- **Salidas estructuradas:** La función `generateObject` combinada con esquemas Zod permite asegurar que las respuestas del modelo se adhieran a una estructura

JSON definida, lo que es vital para el procesamiento programático de los datos de salida.⁹

- **Comprensión de imágenes y documentos:** El AI SDK también es compatible con entradas de imágenes y archivos PDF para los modelos Gemini, lo que permite el procesamiento multimodal de datos.⁹

Además, el AI SDK admite la llamada a funciones, lo que permite a los modelos Gemini interactuar con herramientas personalizadas, y la conexión a tierra de búsqueda, que se puede configurar para que el modelo utilice Google Search para respuestas más precisas y actualizadas.¹ La mención repetida del AI SDK como una "API unificada" que "estandariza la integración de modelos de inteligencia artificial (IA) en todos los proveedores compatibles" ⁸ es un aspecto arquitectónico fundamental. Esto significa que, si bien Google AI Studio es excelente para prototipar los modelos de Google, el AI SDK permite que la lógica de la aplicación resultante sea en gran medida independiente del proveedor, ofreciendo flexibilidad y reduciendo la dependencia de un único proveedor, una consideración clave para aplicaciones de IA robustas.

La siguiente tabla presenta ejemplos de código para integrar Google Gemini con el Vercel AI SDK:

| Característica | Descripción | Importación Clave de AI SDK | Ejemplo de Código (TypeScript/Java Script) | Fuentes Relevantes |
|---------------------------------------|--------------------------------------------------------------------------|--------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|
| Generación de Texto Básica | Generar una respuesta de texto simple a partir de un prompt. | generateText | <pre>typescript import { generateText } from 'ai'; import { google } from '@ai-sdk/google'; async function getTextResponse(prompt: string) { const model = google('gemini- 2.0-flash'); const { text } =</pre> | ⁹ |

| | | | | |
|----------------------------|-------------------------------------------------------------------------|---------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| | | | <pre> await generateText(({ model: model, prompt: prompt, }); return text; } </pre> | |
| Streaming de Texto | Transmitir la respuesta del modelo en tiempo real, ideal para chatbots. | streamText | <pre> typescript i mport { streamText } from 'ai'; import { google } from '@ai-sdk/google '; async function streamChatResp onse(prompt: string) { const model = google('gemini- 2.0-flash'); const { textStream } = await streamText(({ > model: model, prompt: prompt, }); for await (const delta of textStream) { process.stdout. write(delta); } } </pre> | 9 |
| Salida Estructurada | Generar una respuesta que se adhiere a un esquema JSON predefinido. | generateObject, zod | <pre> typescript i mport { generateObject } from 'ai'; import { z } from </pre> | 9 |

| | | | | |
|----------------------------------------------|-------------------------------------------------------------------------------------------------|--------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| | | | <pre>'zod'; import { google } from '@ai-sdk/google '; const userSchema = z.object({ name: z.string(), age: z.number(), city: z.string(), }); async function getStructuredO utput(prompt: string) { const model = google('gemini- 2.0-flash'); const { object } = await generateObject({ model: model, schema: userSchema, > prompt: prompt, }); return object; </pre> | |
| Llamada a Herramientas (Tool Calling) | Permitir que el modelo invoque funciones externas para obtener información o realizar acciones. | generateText, tool | <pre>typescript i mport { generateText, tool } from 'ai'; import { z } from 'zod'; import { google } from '@ai-sdk/google '; const getWeatherTool = tool({ name: 'getWeather', </pre> | 1 |

| | | | | |
|-------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------|--------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---|
| | | | <pre>> description: 'Obtiene el clima actual para una ubicación.', parameters: z.object({ location: z.string().descri be('La ubicación para obtener el clima'), }), execute: async ({ location }) => ({ location, temperature: 25, // Simulación }), }); >async function queryWeather(ci ty: string) { const model = google('gemini- 2.5-flash-previe w-05-20'); const result = await generateText({ model: model, prompt: `¿Cuál es el clima en \${city}?`, tools, }); return result.text; } </pre> | |
| Conexión a Tierra de Búsqueda (Search Grounding) | Habilitar que el modelo utilice Google Search para obtener información actualizada y precisa. | <pre>google({ useSearchGroun ding: true })</pre> | <pre>typescript i mport { generateText } from 'ai'; import { google } from '@ai-sdk/google</pre> | 1 |

| | | | | |
|--|--|--|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|
| | | | <pre> '; async function getGroundingInfo(query: string) { const model = google('gemini- 2.5-flash-previe w-05-20', { useSearchGroun ding: true, }); const { text, sources } = await generateText({ model: model, prompt: query, }); return { text, sources }; </pre> | |
|--|--|--|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--|

Exportación y Adaptación de Prototipos de AI Studio para Vercel

La transición de un prototipo desarrollado en el entorno interno de Google AI Studio a un despliegue externo en Vercel no es un proceso de un solo clic. Google AI Studio es principalmente una herramienta de prototipado basada en chat que puede "generar código" ¹², pero el proceso de exportación para aplicaciones completas no es completamente fluido para Vercel. ¹⁰

Existen desafíos comunes que los desarrolladores deben abordar:

- **Scripts importmap:** El código generado dentro de AI Studio puede incluir scripts importmap que son necesarios para su vista previa interna, pero que a menudo son problemáticos o innecesarios para las compilaciones locales y el despliegue en Vercel. Esto requiere la eliminación o el ajuste manual de estos scripts. ¹⁰
- **Gestión de claves API:** Las claves API de Gemini, obtenidas de Google AI Studio, son esenciales para las aplicaciones externas. Deben gestionarse de forma segura como variables de entorno (por ejemplo, GOOGLE_GENERATIVE_AI_API_KEY) en el entorno de Vercel, en lugar de

codificarlas directamente en la base de código.¹

- **Facturación para funciones avanzadas:** Aunque AI Studio ofrece una capa gratuita, el uso de ciertas funciones avanzadas como Imagen para la generación de imágenes en una aplicación desplegada requiere una clave API de Gemini con una cuenta facturada.¹⁰ Esta es una consideración de costo crítica que debe tenerse en cuenta al planificar el presupuesto de una aplicación de IA.
- **Ajustes manuales del código:** La experiencia de un usuario que intentó desplegar una aplicación de tarjetas de felicitación animadas reveló que el agente de IA en AI Studio puede no resolver completamente los problemas para el despliegue externo. Esto a menudo requiere que los desarrolladores utilicen su "experiencia profesional y la ayuda de otro LLM" para solucionar problemas.¹⁰ Esto subraya la necesidad de habilidades de desarrollo de software tradicionales más allá de la mera ingeniería de prompts.

La experiencia de los usuarios al intentar desplegar aplicaciones generadas por AI Studio a Vercel, encontrando problemas como los scripts importmap y las limitaciones del agente de IA ¹⁰, revela un "problema de la última milla". AI Studio sobresale en la prototipación rápida dentro de su propio entorno, pero la transición a una plataforma de despliegue de producción como Vercel no está completamente automatizada ni es trivial. Un experto debe estar preparado para la adaptación manual del código, la depuración y la comprensión de las diferencias en los entornos de ejecución. Esto desplaza el enfoque de la ingeniería de prompts pura a las habilidades de desarrollo de pila completa.

Mejores Prácticas para Aplicaciones de IA Escalables y Listas para Producción en Vercel

Para construir aplicaciones de IA que no solo funcionen, sino que sean escalables, seguras y rentables en un entorno de producción como Vercel, es fundamental aplicar ciertas mejores prácticas.

Optimización del Rendimiento con Estrategias de Caché

Las inferencias de modelos de IA pueden ser computacionalmente intensivas y añadir latencia. La implementación de estrategias de caché es crucial para mitigar estos desafíos y mejorar la eficiencia de la aplicación.

- **Incremental Static Regeneration (ISR):** Para el contenido generado por IA que no requiere actualizaciones en tiempo real, ISR puede reducir significativamente la carga en los servicios de IA y backend al almacenar en caché las respuestas en el borde de la red de Vercel.¹⁶ Esto es particularmente útil para contenido que cambia con poca frecuencia pero que debe ser entregado rápidamente.
- **Vercel KV (Redis):** Una base de datos Redis gestionada por Vercel, Vercel KV es ideal para almacenar en caché respuestas de IA, gestionar el estado de la aplicación y guardar datos a los que se accede con frecuencia. Esto optimiza aún más el rendimiento y reduce las llamadas a la API, lo que se traduce en una experiencia de usuario más rápida y eficiente.¹⁶

La implementación de caché aborda directamente tanto el costo (menos llamadas a la API) como el rendimiento (tiempos de respuesta más rápidos). Para un experto que construye aplicaciones de producción, esto no es solo una optimización, sino una estrategia fundamental para hacer que las aplicaciones de IA sean económicamente viables y fáciles de usar, especialmente cuando se trabaja con modelos de pago por token.

Garantizar la Seguridad y Fiabilidad para Aplicaciones de IA Desplegadas

La seguridad y la fiabilidad son aspectos no negociables para cualquier aplicación profesional, y las aplicaciones de IA no son una excepción.

- **Características de seguridad de Vercel:** Vercel proporciona características de seguridad incorporadas, como protección contra ataques DDoS y un Firewall de Aplicaciones Web (WAF), que protegen las cargas de trabajo de la aplicación.⁷
- **Gestión segura de claves API:** Es imperativo gestionar las claves API de forma segura utilizando variables de entorno y evitar codificarlas directamente en la base de código. Esto previene la exposición de información sensible en repositorios públicos o entornos de desarrollo.⁹
- **Manejo de errores y mecanismos de reserva:** La implementación de un manejo de errores robusto y mecanismos de reserva en el código de la aplicación, especialmente para las llamadas a modelos de IA, es esencial para garantizar que la aplicación se mantenga estable y proporcione una experiencia de usuario

consistente incluso si el modelo de IA encuentra problemas o filtros de seguridad.⁵

La construcción de una aplicación es solo una parte; construir una aplicación *lista para producción* implica ir más allá de la funcionalidad para asegurar la robustez. La seguridad y la fiabilidad son aspectos críticos que se extienden más allá de la ingeniería de prompts para abarcar la infraestructura subyacente y la calidad del código. Un experto comprende que el modelo de IA es solo un componente de un sistema más grande y robusto.

Consideraciones de Facturación y Gestión de Recursos

Si bien Google AI Studio se anuncia como "rápido y gratuito para empezar" ¹, esta promesa puede ser engañosa para los casos de uso de producción.

- **Costo de funciones avanzadas:** El uso de modelos multimodales avanzados como Imagen para la generación de imágenes en una aplicación desplegada requiere una clave API de Gemini con una cuenta facturada.¹⁰ Esto representa un costo significativo que debe ser considerado en la planificación del proyecto.
- **Monitoreo de uso de tokens:** Es crucial monitorear el uso de tokens y ajustar los parámetros del modelo (por ejemplo, `max_output_tokens`) para controlar los costos asociados con las llamadas a la API de IA.⁵

La mención específica de que Imagen requiere una "cuenta facturada" ¹⁰ es un detalle crítico. Esto resalta que, si bien la prototipación puede ser gratuita, la escalabilidad y el uso de funciones avanzadas en una aplicación desplegada generarán costos. Un experto debe ser plenamente consciente de estas implicaciones de facturación para diseñar soluciones de IA rentables.

Conclusión: Su Viaje hacia la Maestría en AI Studio y Vercel

El camino para convertirse en un experto en la construcción de aplicaciones de IA con Google AI Studio y el despliegue en Vercel implica una comprensión multifacética de la tecnología y las mejores prácticas de desarrollo. Google AI Studio se establece

como un potente entorno de prototipado, ideal para la ideación rápida y la experimentación con los modelos Gemini. Sin embargo, la transición a un despliegue externo en Vercel no es automática y requiere una adaptación deliberada del código generado, aprovechando el Vercel AI SDK como un puente esencial.

La ingeniería de prompts, lejos de ser una tarea superficial, es una disciplina sistemática y fundamental para el desarrollo de aplicaciones de IA profesionales. Implica la creación de instrucciones claras y detalladas, la provisión de contexto exhaustivo, el uso estratégico de ejemplos de pocas tomas, el ajuste preciso de los parámetros del modelo y un proceso iterativo de refinamiento y depuración. Esta aproximación estructurada es lo que permite que las aplicaciones de IA sean fiables y consistentes en entornos de producción.

Vercel, con su infraestructura optimizada para IA y el Vercel AI SDK, se presenta como la plataforma de despliegue ideal para estas aplicaciones. Ofrece las herramientas necesarias para escalar, asegurar y distribuir globalmente las soluciones de IA, garantizando un rendimiento óptimo y una experiencia de usuario fluida.

El campo de la IA está en constante evolución, con la aparición continua de nuevos modelos, técnicas de ingeniería de prompts y estrategias de despliegue en la nube.² Por lo tanto, la "maestría" en este ámbito no es un estado estático, sino un proceso continuo de aprendizaje y adaptación. Se recomienda encarecidamente la experimentación constante con nuevos modelos, las características del SDK y los avances de la plataforma para mantenerse a la vanguardia del desarrollo de aplicaciones de IA. La capacidad de adaptarse y evolucionar con el panorama tecnológico es la verdadera marca de un experto en este dinámico dominio.

Obras citadas

1. Google AI Studio, fecha de acceso: agosto 4, 2025, <https://aistudio.google.com/>
2. A Complete Guide to Google AI Studio - Learn Prompting, fecha de acceso: agosto 4, 2025, https://learnprompting.org/blog/guide_ai_studio
3. Prompt Engineering for AI Guide | Google Cloud, fecha de acceso: agosto 4, 2025, <https://cloud.google.com/discover/what-is-prompt-engineering>
4. 10 Best Practices for Prompt Engineering with Any Model - PromptHub, fecha de acceso: agosto 4, 2025, <https://www.prompthub.us/blog/10-best-practices-for-prompt-engineering-with-any-model>
5. Prompt design strategies | Gemini API | Google AI for Developers, fecha de acceso: agosto 4, 2025, <https://ai.google.dev/gemini-api/docs/prompting-strategies>
6. Prompt engineering overview - Anthropic API, fecha de acceso: agosto 4, 2025,

<https://docs.anthropic.com/en/docs/build-with-claude/prompt-engineering/overview>

7. Vercel: Build and deploy the best web experiences with the AI Cloud, fecha de acceso: agosto 4, 2025, <https://vercel.com/>
8. AI SDK by Vercel, fecha de acceso: agosto 4, 2025, <https://ai-sdk.dev/docs/introduction>
9. Google Gemini Vercel AI SDK Cheatsheet - Patrick Loeber, fecha de acceso: agosto 4, 2025, <https://patloeber.com/gemini-ai-sdk-cheatsheet/>
10. Build Apps with Google AI Studio: Anime Greetings Cards - DEV ..., fecha de acceso: agosto 4, 2025, <https://dev.to/faraib/build-apps-with-google-ai-studio-anime-greetings-cards-9ek>
11. Vertex AI Platform | Google Cloud, fecha de acceso: agosto 4, 2025, <https://cloud.google.com/vertex-ai>
12. AI Code Generation | Google Cloud, fecha de acceso: agosto 4, 2025, <https://cloud.google.com/use-cases/ai-code-generation>
13. Firebase Studio - Google, fecha de acceso: agosto 4, 2025, <https://firebase.google.com/docs/studio>
14. Generative AI | Build AI-powered apps faster with Firebase, fecha de acceso: agosto 4, 2025, <https://firebase.google.com/products/generative-ai>
15. A Complete Guide To Vercel's AI SDK // The ESSENTIAL Tool For Shipping AI Apps, fecha de acceso: agosto 4, 2025, <https://www.youtube.com/watch?v=mojZpktAiYQ>
16. How to build scalable AI applications - Vercel, fecha de acceso: agosto 4, 2025, <https://vercel.com/blog/how-to-build-scalable-ai-applications>
17. A Practical Guide to Using Vercel AI SDK in Next.js Applications - Telerik.com, fecha de acceso: agosto 4, 2025, <https://www.telerik.com/blogs/practical-guide-using-vercel-ai-sdk-next-js-applications>